

Ruang lingkup: simulation/data_prep.py serta customer_ml_dataset.csv, customer_train.csv, dan customer_test.csv.

1. Tujuan

Skrip data_prep.py menyiapkan data e-commerce untuk latihan machine learning klasifikasi customer churn. Alurnya adalah membaca data sumber, memvalidasi struktur, membersihkan serta merekayasa fitur, membagi data train/test, lalu menghasilkan laporan kualitas data.

2. Data sumber dan validasi

Skrip membaca customers.csv, orders.csv, product_summary.csv, dan monthly_revenue.csv dari folder simulation. Fungsi validate_sources memastikan setiap file memiliki kolom penting, sehingga kesalahan memilih dataset diketahui sejak awal.

3. Penyiapan fitur pelanggan

Tabel customers menjadi basis dataset model. Kolom kategorikal dipertahankan sebagai teks agar encoding dapat dilakukan kemudian di pipeline machine learning tanpa kebocoran data train/test.

Fitur kategorikal: country, gender, membership_tier, preferred_category, preferred_device, preferred_payment_method, dan acquisition_channel.

Fitur numerik awal: age, total_orders, total_spend_usd, avg_order_value_usd, days_since_last_purchase, reviews_given, avg_review_score, returns_made, wishlist_items, serta newsletter_subscribed.

4. Rekayasa fitur

Snapshot data ditetapkan sebagai tanggal paling akhir dari orders dan customers, yaitu 1 April 2026.

Dari sini dibuat customer_tenure_days, orders_per_year, reviews_per_order, dan returns_per_order.

Pembagi jumlah pesanan nol ditangani sehingga rasio ulasan/retur menjadi 0, bukan nilai tak terdefinisi.

Target churned dikonversi menjadi integer biner: 0 berarti pelanggan tidak churn dan 1 berarti churn.

5. Pembagian data dan keluaran

Dataset akhir dibagi secara stratified menjadi 80% train dan 20% test, dengan random_state=42.

Stratifikasi menjaga proporsi kelas churn di kedua subset.

customer_ml_dataset.csv berisi seluruh 8.000 pelanggan siap-model. customer_train.csv berisi 6.400 baris untuk pelatihan. customer_test.csv berisi 1.600 baris untuk evaluasi. Ketiganya memiliki 23 kolom: customer_id, 21 fitur sebelum one-hot encoding, dan target churned.

6. Contoh isi

Satu baris mewakili satu pelanggan. Contoh C00001: pelanggan Amerika Serikat, laki-laki, tier Free, 4 pesanan, total belanja USD 286,63, tenure 2.631 hari, dan churned=0. Artinya pelanggan tersebut tidak churn.

7. Kualitas data

Laporan data_quality_report.json mencatat 8.000 pelanggan, 25.000 pesanan, 140 ringkasan produk, dan 75 ringkasan bulanan. Tingkat churn pelanggan adalah 8,94%; tingkat retur pesanan 8,08%; dan 63,0% pesanan tidak memiliki rating pelanggan.

Pendapatan product_summary sesuai dengan pesanan non-cancelled, sedangkan monthly_revenue sesuai dengan pesanan berstatus Delivered. Karena ringkasan bulanan hanya menggunakan pesanan terkirim, return_rate di sana selalu nol; analisis retur sebaiknya memakai orders.csv.

8. Kesimpulan

data_prep.py menghasilkan dataset yang konsisten dan siap digunakan pada pipeline klasifikasi churn. ID pelanggan sengaja dipertahankan agar setiap baris dapat ditelusuri ke data sumber, tetapi ID tidak boleh digunakan sebagai fitur model.